



PROJET DE FIN D'ANNEE - 2025-2026

RiskGuard Pro

Plateforme Intelligente de Detection de Risque Bancaire pour Entreprises

Etudiant(s)

[A completer]

Encadrant

[A completer]

Universite

[Logo / Nom]

Annee universitaire 2025 - 2026



PLAN DE LA PRESENTATION

Sommaire

1 Contexte & Problematique

2 Objectifs du projet

3 Donnees & Pretraitement

4 Donnees synthetiques (SMOTE + Bruit Gaussien)

5 Comparaison des modeles ML

6 Pourquoi XGBoost ?

7 Architecture technique

8 Demonstration

9 Resultats & Metriques

10 Conclusion & Perspectives

POURQUOI CE PROJET ?


Contexte & Problematique

- Le secteur bancaire marocain fait face a un risque croissant de defaillance d'entreprises.
- Les methodes traditionnelles (scoring manuel, ratios simples) sont limitees et subjectives.
- Besoin d'un outil automatise, fiable et rapide pour classifier le niveau de risque.

Question centrale

Comment predire la probabilite de faillite d'une entreprise a partir de ses ratios financiers ?

Hausse des defaillances



— CE QUE NOUS VOULONS LIVRER

Objectifs du projet



Pipeline ML complet

De la donnée brute à la prédiction temps réel.



4 niveaux de risque

Faible - Modéré - Élevé - Critique.



Interface web intuitive

Pensée pour les analystes bancaires.



Interprétabilité (SHAP)

Expliquer chaque décision du modèle.



Analyse unitaire & batch

Saisie manuelle ou import CSV / Excel.



Réponse temps réel

Prédiction en moins de 100 ms.

LE JEU DE DONNEES


Donnees utilisees

- Source : "Company Bankruptcy Prediction" (Taiwan Economic Journal).
- 96 colonnes de ratios financiers : ROA, ROE, liquidite, endettement, tresorerie...
- Cible : Bankrupt? - 0 = sain, 1 = defaillant.
- Environ 6 800 observations initiales.

Probleme majeur

Desequilibre extreme des classes : ~3 % de faillites contre 97 % d'entreprises saines.

Desequilibre des classes




PRETRAITEMENT

Data Cleaning

- 1 Detection & suppression des doublons.
- 2 Valeurs manquantes : imputation par la mediane (robuste aux outliers).
- 3 Detection des outliers via IQR - capping aux percentiles 1 % et 99 %.
- 4 Suppression des features a variance quasi-nulle (>95 % de valeurs identiques).
- 5 Correlation : suppression des features avec correlation > 0.95 (multicolinearite).
- 6 Normalisation des noms de colonnes.

Reduction des features



96 features -> ~65 pertinentes

Pipeline de nettoyage

Doublons -> Imputation -> IQR capping -> Variance -> Correlation -> Normalisation.

LE PIEGE DU DESEQUILIBRE

Pourquoi generer des donnees synthetiques ?

- Avec ~3 % de cas positifs, le modele apprend a toujours predire "sain".
- Accuracy trompeuse : 97 % en predisant toujours 0 -> inutile !
- Le recall sur la classe "faillite" est quasi nul sans reequilibrage.
- Solution : augmenter la classe minoritaire avec des donnees synthetiques realistes.

Matrice de confusion - avant / apres

Sans reequilibrage

0	97	0
1	3	0
	Pred 0	Pred 1

Apres reequilibrage

0	88	9
1	1	12
	Pred 0	Pred 1

— GENERATION DE DONNEES SYNTHETIQUES

SMOTE + Bruit Gaussien

1. SMOTE - Synthetic Minority Over-sampling

Crée de nouveaux exemples en interpolant entre voisins proches (k-NN).
Pour chaque exemple minoritaire, un point est généré sur le segment vers un voisin.


$$x_{\text{new}} = x_i + \lambda * (x_{\text{voisin}} - x_i) \quad \lambda \in [0,1]$$

2. Ajout de bruit gaussien


Un léger bruit normal est ajouté à chaque feature pour éviter des données trop "lisses" et introduire une variabilité réaliste, limitant le sur-apprentissage.

$$x_{\text{final}} = x_{\text{smote}} + e \quad e \sim N(0, \sigma^2), \sigma = 0.01 * \text{ecart-type}$$

Interpolation SMOTE



Bruit gaussien $N(0, \sigma^2)$



MULTI-CLASSIFICATION

4 classes de risque

Le probleme binaire devient une echelle de risque, plus utile aux analystes qu'un simple oui / non.

0 - 25 %

Faible

Entreprise financiere ment saine.

25 - 50 %

Modere

Vigilance requise.

50 - 75 %

Eleve

Risque significatif, surveillance active.

75 - 100 %

Critique

Risque imminent de defaillance.

Faible

Modere

Eleve


Critique

COMPARAISON DES MODELES ML

Benchmark des modeles testes

Modele	Accuracy	F1	AUC-ROC	Entrainement
Regression Logistique	78 %	0.72	0.81	Tres rapide
Random Forest	89 %	0.86	0.92	Moyen
SVM (RBF)	82 %	0.78	0.85	Lent
KNN	80 %	0.75	0.83	Rapide
XGBoost *	94 %	0.93	0.97	Moyen
LightGBM	93 %	0.91	0.96	Rapide

F1-Score par modele



* XGBoost domine sur toutes les metriques.

JUSTIFICATION DU CHOIX

Pourquoi XGBoost ?

**Performance superieure**

Meilleur F1 & AUC-ROC.

**Gestion du desequilibre**

scale_pos_weight.

**Regularisation L1 + L2**

Evite le sur-apprentissage.

**Robuste aux outliers**

Arbres de decision.

**Feature importance**

Interpretabilite native.

**Compatible Optuna**

Tuning bayesien (30 essais).

**Inference rapide**

< 100 ms par requete.

**Ecosysteme mature**

Standard de la finance.

Gradient Boosting - arbres sequentiels

Chaque arbre corrige les erreurs du precedent.

Pourquoi pas les autres ?

- Reg. logistique : pas de non-linearites.
- SVM : lent, peu interpretable.
- Random Forest : sans boosting sequentiel.
- Deep Learning : trop complexe, boite noire.

OPTIMISATION DES HYPERPARAMETRES

Tuning avec Optuna

- Optimisation bayésienne - plus intelligente que Grid Search.
- 30 essais d'optimisation automatique.
- Validation croisée stratifiée (5-fold) pour chaque configuration.

Hyperparametres optimises

max_depth

learning_rate

n_estimators

subsample


colsample_bytree

reg_alpha

reg_lambda

Convergence des essais Optuna

AUC-ROC



— ARCHITECTURE TECHNIQUE

Architecture de la plateforme

Frontend

HTML / CSS / JS pur

Interface responsive

Dashboard KPIs & graphiques

Tableau d'historique

Mode demo (15 entreprises MA)

★ REST / JSON

Backend

FastAPI - Python

API RESTful - 8 endpoints

Validation Pydantic

Generation de rapports PDF

Base SQLite (historique)

★ appel modele

ML Pipeline

XGBoost - joblib

Preprocessing -> Feature selection

XGBoost -> SHAP

Modele serialise (joblib)

Prediction multi-classes + proba

FONCTIONNALITES CLES

Fonctionnalites

Analyse unitaire

Saisie manuelle des ratios financiers.

Analyse batch

Upload CSV / Excel multi-entreprises.

Dashboard

Distribution des risques & tendances.

Historique

Analyses filtrables et paginées.

Export PDF

Rapport détaillé + recommandations.

Interprétabilité

SHAP values par prédiction.

Temps réel - réponse en moins de 100 ms par requête.



DEMONSTRATION EN DIRECT

Place a la demo



Scenario 1

Entreprise a risque faible.



Scenario 2

Entreprise a risque critique.



Scenario 3

Upload batch d'un fichier CSV.



Rapport PDF

Generation & export du rapport.

Note au presentateur : preparer le backend lance (uvicorn main:app --port 8000) + le fichier test_batch.csv.



— RESULTATS DU MODELE FINAL

Resultats & Metriques

94 %

Accuracy globale

0.93

F1-Score macro


0.97

AUC-ROC


Matrice de confusion

Sain	1577	43
Faill.	33	311
	Pred Sain	Pred Faill.

Courbe ROC



Top 5 features importantes



BILAN

Conclusion

- ✓ Pipeline ML complet de bout en bout.
- ✓ Resolution du desequilibre via SMOTE + bruit gaussien.
- ✓ XGBoost : choix justifie par les performances et l'interpretabilite.
- ✓ Plateforme web fonctionnelle et intuitive.
- ✓ Applicable au contexte bancaire marocain.

— ET APRES ?

Perspectives & Ameliorations



Donnees reelles marocaines

Bank Al-Maghrib, OMPIC.



Donnees textuelles (NLP)

Rapports d'audit analyses.



Deploiement cloud

AWS / Azure en production.



Monitoring du modele

Detection de drift.



Extension PME / TPE

Features adaptees.



API publique

Integration tierce (SaaS).



Merci pour votre attention

Questions ?

Etudiant(s)
[A completer]

Contact
[email]

GitHub
[achrafbaaiz/riskguard-pro](https://github.com/achrafbaaiz/riskguard-pro)



QR -> depot GitHub du projet